

目录

CONTENTS



01. 主数据治理的概况

02. AI在主数据清洗的应用

03. AI在主数据治理的展望

主数据治理目标&现状

主数据治理框架



平台层面

- 建立覆盖公司级的统一主数据管理平台，实现主数据审核、主数据分发、主数据模型、主数据质量等功能。
- 完成与各业务系统的对接改造，确保“数据同源”。

标准层面

- 建立公司级主数据规范和标准，落地主数据管理体系和流程，实现业务主数据的强关联管控。
- 分主题推进业务主数据建设，在已完成药品、客户、供应商、中药饮片基础上，推进器械、用户等主数据建设。

成果层面

- 从2017年到现在，累计积累主数据约114万条（药品：17万条，客户供应商：74.6万条，饮片：22.1万条）。
- 其中，覆盖国家医保目录11.3万条，建立ATC分类16.8万条、客商地址信息73万条等。

主要挑战

- ① 400w+待清洗数据，且源源不断增加
- ② 型号、规格数据结构超5000种
- ③ 参考数据为非结构化数据
- ④ 产品分类需要专业知识积累
- ⑤ 噪声和错误数据占比高


VS

传统清洗方案的瓶颈

- ① 在清洗过程中产生新的数据问题
- ② 清洗规则难以穷举
- ③ 非结构化数据的识别问题
- ④ 专家共识的建立问题
- ⑤ 需要大量人工来完成质量校验

用户主数据建设背景&目标

1. 线下、线上各类零售渠道，在实际业务开展过程，在不同业务中、在不同场景下，会记录不同颗粒度的用户数据、交易数据；
2. 会员、营销等系统，需要基于用户标签、用户画像，开展针对性营销活动，发放用户权益，跟踪营销效果等；



数据清洗的核心难点


1、引入AI开展数据清洗

UserID	姓名	性别	手机号	身份证号	教育程度	血型	省	市	区	创建时间
QC_DTP_001	张大! ->张大	男性->男	138****1234		本科		四川->四川省			2023-03-14

2、OneID生成：确定性规则

OneID	UserID	姓名	性别	手机号	身份证号	教育程度	血型	省	市	区	创建时间	病种	确诊医院	购药门店	收货人名称	收货人电话
10000000001	QC_DTP_001	张大	男	138****1234		本科		四川省			2023-03-14					
10000000001	CMS_RTL_001	张大	男	138****1234	1310*****1135				成都市		2023-04-15	肺癌	成都医科大学	医科大店	张龙一	136****0344
10000000001	GD_DTP_001	张龙		138****1235					成都市		2023-04-15	肺癌	成都医科大	医科大店	张龙	136****0344

4、应用图计算解决One识别问题




3、OneID生成：非确定性规则

关系深度	关系型数据库执行时间 (S)	图数据库(Neo4j)执行时间 (S)	返回记录数(条)
2	0.016	0.01	约2500
3	30.267	0.168	约110000
4	1543.505	1.359	约600000
5	未完成	2.132	约800000

项目产出成果

主要成果：1、打通各业务源头，实现OneID的识别，为精准营销建立基础。
2、识别用户最佳记录，同时识别异常用户数据。

精准定位异常用户




标记异常用户状态，优化服务流程。

项目产出成果

主要成果：1、打通各业务源头，实现OneID的识别，为精准营销建立基础。
2、识别用户最佳记录，同时识别异常用户数据。

精准定位异常用户



标记异常用户状态，优化服务流程。

AI清洗策略总结-重复学习&迭代

- ✓ 数据清洗是数据治理的关键环节之一，耗时长、成本巨大、直接左右项目最终质量。
- ✓ 基于有监督学习、强化学习的原理，引入AI到数据清洗、数据质量校验等环节，实现提效。



基于规则的传统清洗方式优缺点

优点

高度可控

依赖人工定义的规则（如正则表达式、逻辑条件）进行数据清洗，清洗过程高度可控，结果解释性强。

易于调试

领域专家定义和维护规则，对简单、结构化数据效果较好。

技术成熟

已有丰富的实践经验和工具支持，实施成本相对较低。

规则驱动

缺点

局限性高

规则的覆盖面有限，无法处理复杂的异常数据，处理大规模数据性能有限、处理复杂数据质量问题时结果不稳定。

适应性差

无法应对多变的数据质量问题，规则固定，不具备自适应能力。

自动化弱

高度依赖人工编写规则和维护，需要大量人工干预调整，效率低下。

AI在数据治理中的其他应用场景

AI（人工智能）在主数据治理中的应用日益广泛，显著提升了数据管理的效率和质量，典型应用场景如下：

1. 自动化数据分类与标签

智能分类：AI可以根据数据的内容自动进行分类，将数据分类到预定义的类中或分配相关标签，使得搜索、检索和分析数据变得更加容易。

属性补全：面对数据属性缺失的问题，AI可以通过分析已有数据，自动补全缺失的属性值，提高数据的完整性

2. 数据清洗、预处理，数据质量实时监控

错误识别与纠正：AI技术，特别是机器学习算法，能够从历史数据中学习并自动识别和纠正错误从而确保数据的质量。

重复数据删除：AI可以帮助识别和删除大型数据集中的重复记录。

数据标准化：AI技术可以应用于数据标准化过程，确保不同数据源之间的数据格式、命名规则等保持一致，便于数据集成和分析。

3. 自动化合规性检查与报告

数据处理合规：AI辅助实现自动化合规性审计，确保数据处理符合各种法规要求（GDPR、HIPAA、个保法等），自动生成所需的报告，减少人工审计的工作量和成本。

提高数据管理的效率和准确性

降低数据治理的成本

增强数据的安全性和合规性